Relatório de Laboratório

Lab03 — Mineração de Métricas DORA | Relatório final da Sprint 3

Curso	Engenharia de Software
Disciplina	Laboratório de Experimentação de Software
Turno / Período	Noite / 6º
Professor(a)	Danilo Maia
Laboratório	Lab03 — Mineração de Métricas DORA | Sprint 3
Grupo (trio)	Arthur Bacelete · Bernardo Augusto · João Tavares
Link do repositório / GitHub Projects	github.com/BernardoApl/metrica-software github.com/users/BernardoApl/projects/2/views/1
Data de entrega	22/10/2026

PANORAMA DA SPRINT 3

300 repositórios analisados | 18.206 releases | 861.659 execuções válidas de CI

7 questões de pesquisa (RQ01–RQ07) | 8 entregas analíticas (RQ91–RQ98)

199 testes automatizados aprovados na auditoria local

1. Introdução

O Lab03 investiga o desempenho de entrega de software em repositórios open-source com CI/CD no GitHub Actions. As quatro métricas DORA abrangem velocidade — frequência de deploy e lead time for changes — e estabilidade — change failure rate (CFR) e tempo de recuperação. O GitHub não mede diretamente produção: releases e execuções de CI são proxies que exigem validação e cuidado interpretativo. A Sprint 3 analisa as RQ01–RQ07 com a base minerada nas Sprints 1 e 2.

Perguntas de pesquisa: RQ01 frequência de deploy; RQ02 lead time nas variantes por release e por commit; RQ03 CFR pelas variantes de CI e entrega; RQ04 tempo de recuperação; RQ05 correlação entre frequência e CFR; RQ06 associação entre características dos projetos e DORA; RQ07 sensibilidade das classificações à definição operacional.

Hipóteses registradas na introdução do artigo antes das análises: H1 esperava 0,5–1 release/semana; H2, lead time por commit geralmente menor; H3, CFR de entrega menor que CFR de CI; H4, recuperação em horas; H5, ausência de trade-off forte; H6, associações com equipe, linguagem e idade em geral pequenas; H7, classificação sensível às definições. O confronto dessas expectativas com os dados aparece na seção 4.3.

Base: entregas/laboratorio-03/artigo/introducao.tex, com hipóteses informais prévias. RQ91–RQ98 são identificadores de Issues da Sprint 3; RQ01–RQ07 são perguntas de pesquisa do enunciado.

2. Contexto

A amostra final contém 300 repositórios. A janela aplicada nos arquivos é de 01/10/2025 a 30/09/2026 (12 meses), mas a própria configuração marca janela_confirmada=false; portanto, ela permanece PROVISÓRIA até confirmação do professor. Foram avaliados 778 candidatos para alcançar a meta, a partir de uma lista inicial de 8.000. O filtro considera pelo menos cinco releases e 50 workflow runs válidos, na branch padrão, com eventos push para CI.

A unidade de análise é o repositório: medianas e quartis da amostra são calculados sobre a métrica por repositório, evitando que um projeto com milhares de releases ou runs domine a estatística central. Classes Elite/High/Medium/Low seguem os cortes didáticos fixados no enunciado. A comparação não estabelece causalidade nem equivale automaticamente a desempenho de produção.

3. Metodologia

3.1 Principais desafios

A coleta enfrentou limites de API, paginação, diversidade de nomes/semânticas das tags, disponibilidade desigual de commits e diferenças de volume entre projetos. Na análise, os desafios centrais foram manter a integridade da amostra, tratar censura de episódios de falha, distinguir falha de CI de falha real de entrega e comparar classificações produzidas por definições operacionais distintas.

O ZIP contém scripts e planilhas de preparação da amostra-ouro, mas não contém as três planilhas humanas independentes e o consenso final necessários à apuração do kappa de Fleiss e do F1 real da heurística corretiva. Há uma planilha identificada explicitamente como “ASSISTIDA_IA”, que não substitui a amostra-ouro humana. Os resultados de CFR (b) são, portanto, condicionais à heurística ainda não validada.

3.2 Tomadas de decisão

Adotou-se releases publicadas (não draft, não prerelease) como unidade principal de deploy; para RQ07, também foram consideradas variantes com pré-releases e tags. Lead time foi avaliado por release (commit mais antigo) e por commit (mediana dos commits da janela). CFR (a) é a razão entre runs falhos e runs com conclusão válida; CFR (b) é definido pela ocorrência de release corretiva em até sete dias após a release candidata. As versões da heurística de correção foram mantidas separadas e rastreáveis.

Foram adotadas mediana e intervalo interquartil (IQR); Spearman na RQ05; Kruskal–Wallis ou Mann–Whitney e correção de Holm na RQ06; kappa de Cohen ponderado na RQ07. Valores não estimáveis e censurados são explicitados, nunca convertidos em zeros. A correção de fechamento de janela da RQ92 foi utilizada na RQ93.



Figura 1 — Fluxo efetivamente representado pelos módulos e entregas do repositório.

3.3 Etapas e rastreabilidade do desenvolvimento

Sprint	Entregas verificadas no ZIP	Issues / participação indicada
S01	Busca de candidatos, metadados, releases, runs, cache e testes.	RQ73–RQ81; grupo
S02	Coleta final, métricas variantes, dataset e rotulação/validação em preparação.	RQ82–RQ90; grupo
S03	Estatística descritiva e inferencial, classes C1–C7, gráficos e artigo.	Bernardo: RQ91–93; Arthur: RQ94–96; João: RQ97–99

Distribuição dos responsáveis conforme planejamento informado pelo grupo nesta conversa; a confirmação de Assignees/commits deve ser feita no GitHub Projects. O ZIP não contém captura do board para incluir como evidência visual; não foi inventado um print. A política de WIP efetiva também depende de verificação no quadro.

3.4 Ferramentas

Python 3; API REST/GraphQL do GitHub; GitHub Actions; Pandas/NumPy para preparação e estatística descritiva; SciPy para Spearman, Wilcoxon e Kruskal–Wallis; statsmodels/scikit-learn para procedimentos estatísticos e comparações; Matplotlib para figuras; pytest para testes; GitHub Projects para gerenciamento e rastreabilidade. Os scripts aceitam entradas locais, sem necessidade de rede para reproduzir as análises da S03.

Na auditoria local, os oito módulos de testes das RQ91–RQ98 passaram integralmente: 199 testes aprovados, com execução offline utilizando os artefatos do ZIP. Isso comprova a execução desses testes, não valida por si só a semântica das proxies ou a rotulação humana.

3.5 Tabela de métricas

Pergunta	Indicador / definição operacional	Unidade	Fonte
RQ01	Releases publicadas na janela ÷ 52,14 semanas	releases/sem	RQ91 · releases.csv
RQ02	Mediana (data release − data commit) por release / por commit	dias	RQ94 · lead_time_releases.csv
RQ03	(a) runs falhos / runs válidos; (b) releases seguidas de corretiva em ≤7 dias / releases avaliadas	fração (%)	RQ97 · runs e releases
RQ04	Mediana do tempo da primeira falha ao sucesso seguinte do mesmo workflow	horas	RQ92 · workflow_runs.csv.gz
RQ05	ρ de Spearman: frequência × CFR (a) e (b)	ρ, p	RQ98 · CSV local
RQ06	Fator × métrica: KW/MW, Holm, ε^2 e Cliff δ	p ajustado / efeito	RQ93 · testes_holm.csv
RQ07	% de troca de classe C1–C7 e κ de Cohen ponderado	% / κ	RQ96 · pares.csv

3.6 Inovações propostas pelo grupo (30%)

As contribuições além da análise básica são verificáveis em entregas de Sprint 3: (i) RQ91 calculou cadência mensal, extremos e concentração de releases; (ii) RQ92 realizou auditoria de fechamento da janela, separou censura à esquerda e à direita e mediu a recuperação nos horizontes 1 h, 24 h e 168 h; (iii) RQ94 analisou releases intercaladas e tamanho da release como possível fonte de divergência entre variantes; (iv) RQ97 comparou três heurísticas de release corretiva; (v) RQ98 adicionou análises de robustez e linha de base nula/permutação para investigar a correlação entre frequência e CFR (b).

Essas extensões enriquecem a interpretação e a auditoria, mas o estatuto de “30% de inovação” depende da avaliação docente. Nenhum F1 humano é atribuído às heurísticas v1–v3; seus contrastes atuais são análises de sensibilidade, não validação definitiva.

4. Resultados

4.1 Coleta de dados e quadro geral

A coleta final selecionou 300 repositórios após avaliar 778 candidatos dentre 8.000 inicialmente levantados. O artefato da RQ91 registra 18.206 releases principais; a RQ92 leu 948.146 runs, dos quais 861.659 válidos segundo os filtros e conclusões. O lead time pôde ser estimado para 14.589 releases. Vinte repositórios não tiveram recuperação estimável; por isso, 280 têm classe DORA geral na combinação C1.

Indicador	Valor observado	Interpretação
Amostra final	300 repositórios	Meta de tamanho da amostra atingida
Candidatos examinados	778 de 8.000	Busca encerrada após meta da amostra
Releases principais	18.206	Proxy de deploy, não produção
Runs válidos	861.659	Entre 948.146 runs lidos
Repositórios com recuperação	280	20 sem tempo recuperável estimável
Classes gerais C1	18 Elite · 122 High · 128 Medium · 12 Low	20 sem classificação geral

4.2 Visualização gráfica e respostas às RQs

RQ01 — Qual a frequência de deploy? Mediana de 0,4795 release/semana; Q1–Q3 de 0,2301–1,1555. As classes de frequência são 5 Elite, 75 High, 152 Medium e 68 Low. Os 30 mais ativos concentram 51,53% das releases; outliers foram mantidos.

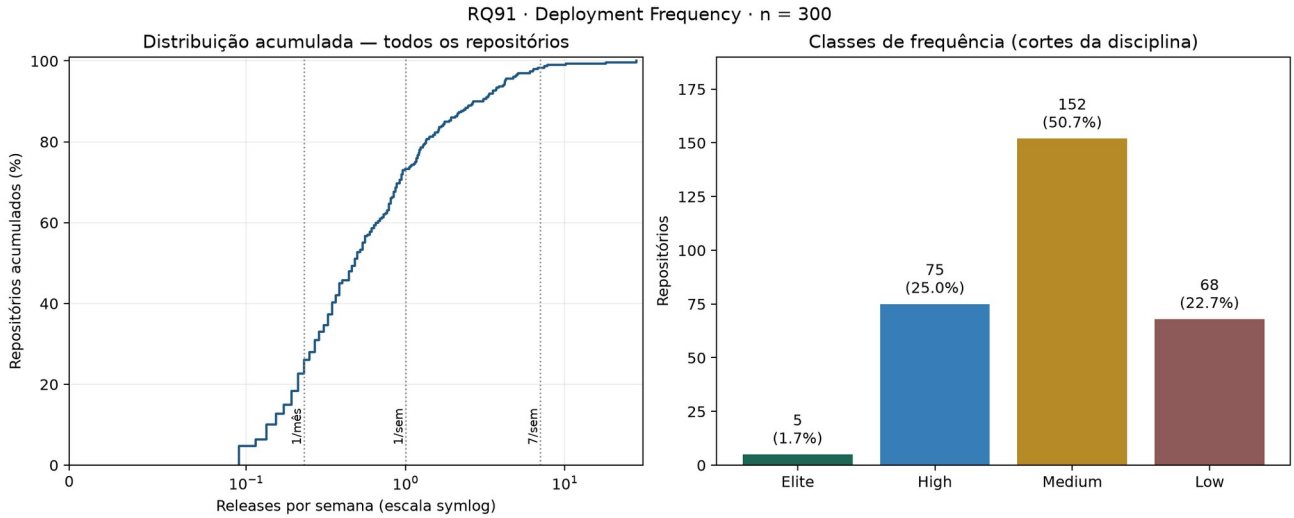


Figura 2 — RQ01: distribuição acumulada e classes de frequência (fonte: RQ91).

RQ02 — Qual o lead time das mudanças? A variante por release tem mediana de 10,47 dias (IQR 35,91); por commit, 12,06 dias (IQR 54,25). A comparação pareada entre variantes não foi significativa (Wilcoxon p=0,115);

127 de 300 repositórios mudam de classe ao trocar a definição. A base inclui 890 commits com lead time negativo, registrados para auditoria.

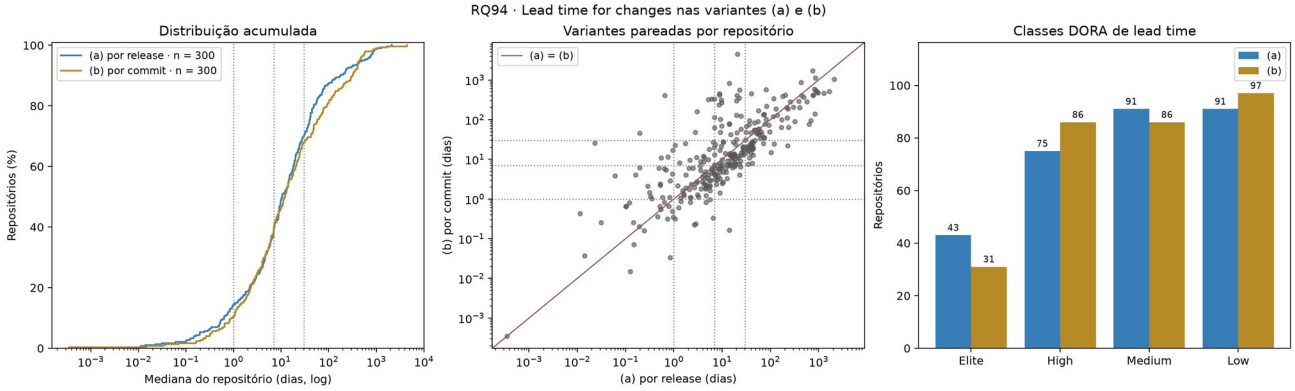


Figura 3 — RQ02: variantes de lead time e efeito na classificação (fonte: RQ94).

RQ03 — Qual a taxa de falha? A mediana do CFR (a) de CI foi 4,57%; a do CFR (b) de entrega, com heurística SemVer v1, foi 18,75% (n=299). Entre as variantes, 171 de 299 repositórios (57,2%) mudam de classe; κ ponderado=0,022. As versões alternativas v2 e v3 de heurística elevam a mediana de CFR (b) a 43,48% e 27,27%, respectivamente. Os números não devem ser tratados como defeitos em produção validados.

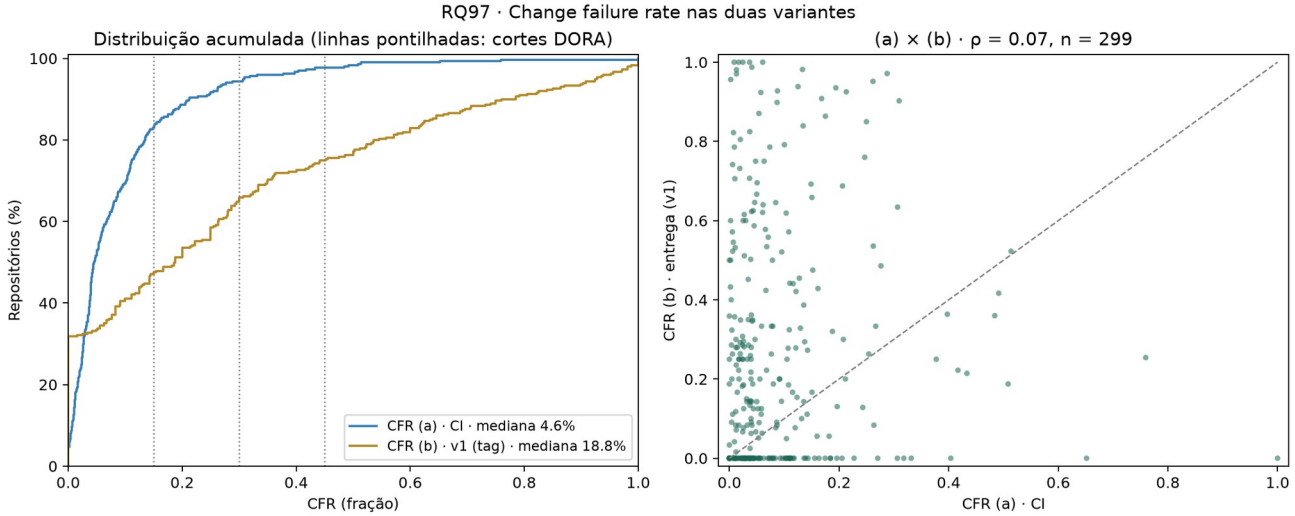


Figura 4 — RQ03: grande divergência entre proxies de CI e entrega (fonte: RQ97).

RQ04 — Quanto tempo para recuperar após uma falha de CI? Em 280 repositórios estimáveis, mediana de 2,72 horas (Q1 1,11; Q3 6,85). Foram identificados 27.839 episódios, 27.379 completos e 460 com algum tipo de censura; 230 apresentam censura à direita. A estimativa não imputa zero nos 20 repositórios sem recuperação completa.

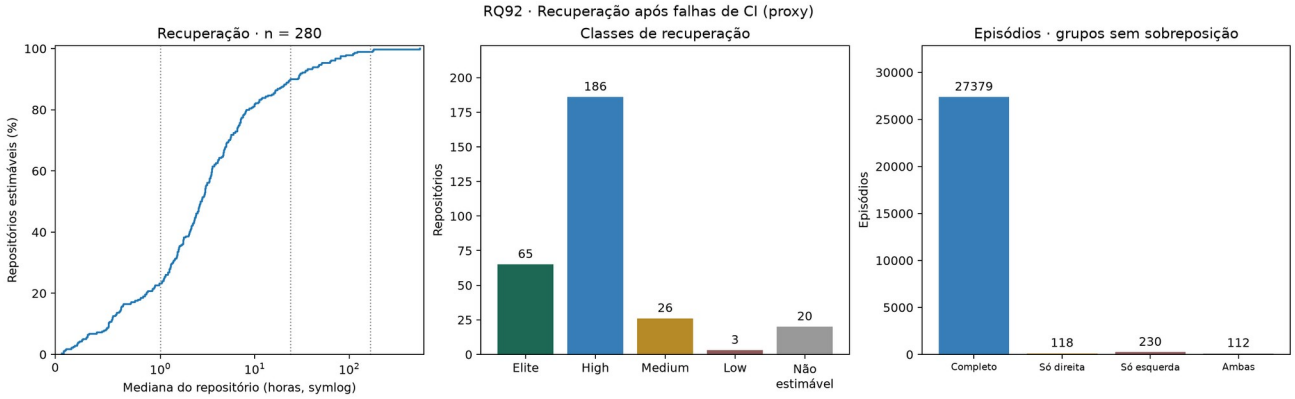


Figura 5 — RQ04: distribuição, classes e censura dos episódios (fonte: RQ92).

RQ05 — Frequência e taxa de falha se relacionam? Spearman indica correlação positiva fraca para CFR (a): ρ=0,150, p=0,0091 (n=300); e positiva moderada para CFR (b): ρ=0,398, p<0,001 (n=299). A análise adicional de oportunidade de patches e o modelo nulo mostram que parte da associação com CFR (b) decorre mecanicamente de publicar mais releases. Isso não demonstra que publicar mais cause defeitos.

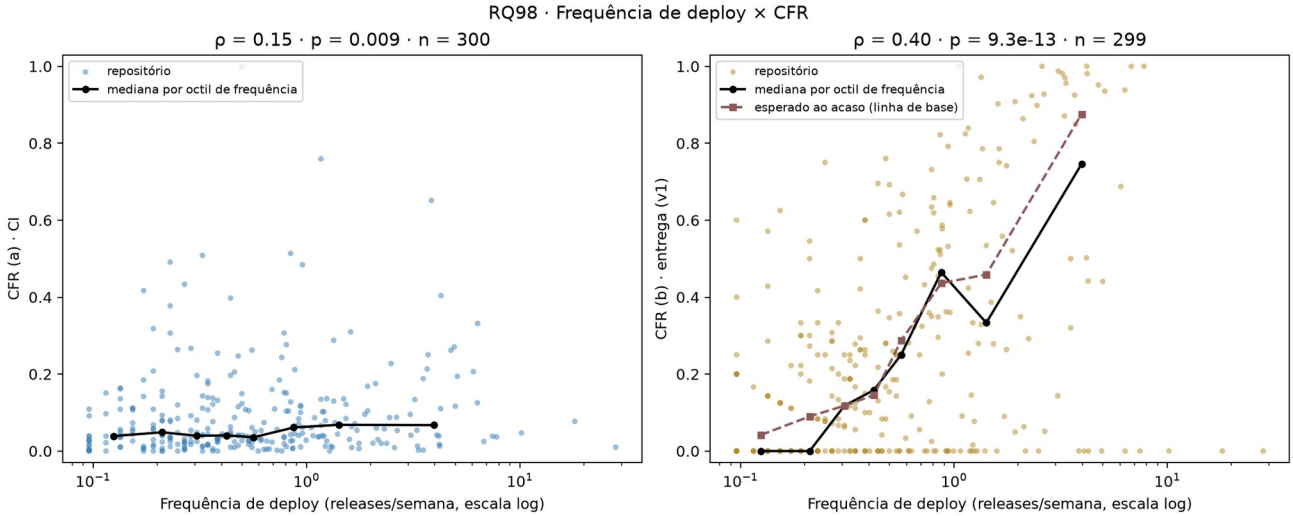


Figura 6 — RQ05: correlação de Spearman nos dois proxies, com linha de base (fonte: RQ98).

RQ06 — Quais atributos estão associados ao DORA? A RQ93 testou 4 fatores (contribuidores, estrelas, idade e linguagem) × 4 métricas. Quatro dos 16 testes principais permaneceram significativos após Holm: contribuidores × lead time, idade × frequência, idade × lead time e linguagem × lead time. Os tamanhos de efeito ε^2 desses testes são 0,168; 0,099; 0,337; 0,148, respectivamente. Há 11 contrastes pareados sustentados após correção; não há inferência causal.

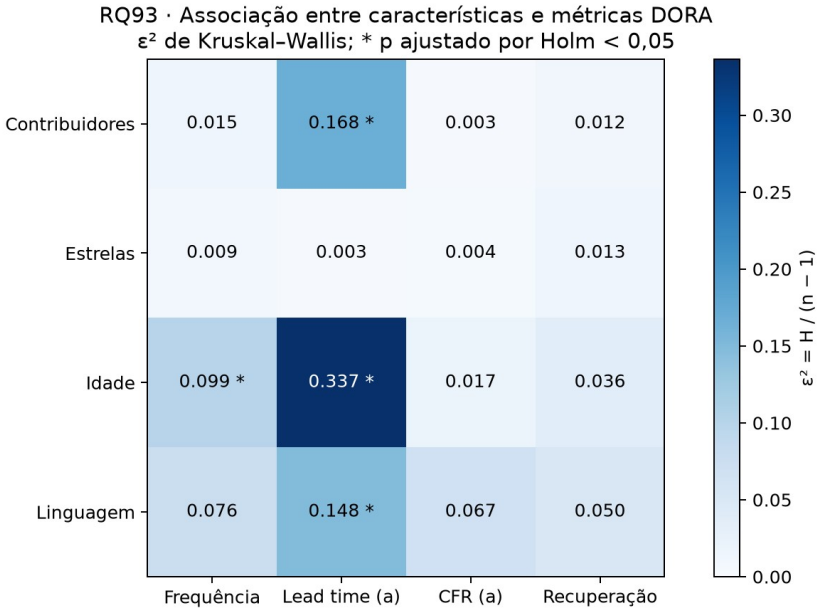


Figura 7 — RQ06: mapa de efeitos ε^2; asteriscos indicam p ajustado < 0,05 (fonte: RQ93).

RQ07 — A classificação DORA depende da operacionalização? Foram comparadas C1–C7. Entre 279 repositórios com classe em todas as combinações, 116 (41,6%) mudam em alguma alternativa. Frente à C1, a troca apenas da unidade de deploy altera 3,6% a 10,7%; combinações com CFR (b) alteram até 35,5%. O impacto varia consideravelmente conforme a proxy, com concordância medida por κ linear ponderado.

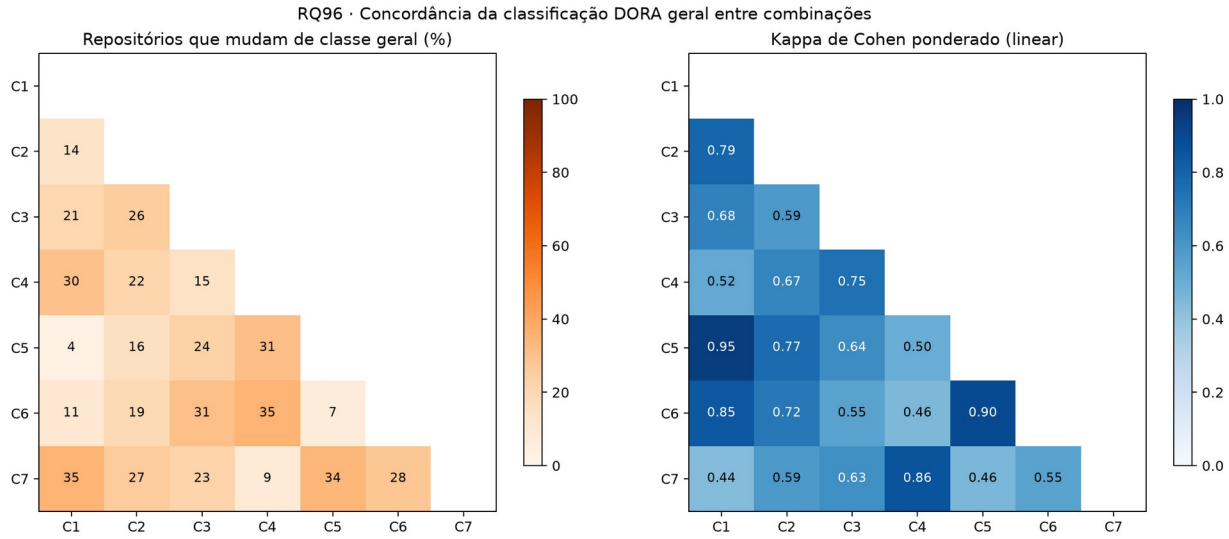


Figura 8 — RQ07: mudanças de classe e concordância κ entre combinações (fonte: RQ96).

Classificação geral de referência (C1) — Com releases, lead time por release e CFR de CI, dos 280 repositórios classificados: 18 Elite (6,4% dos classificados), 122 High (43,6%), 128 Medium (45,7%) e 12 Low (4,3%). Outros 20 permanecem indefinidos por não terem recuperação estimável.

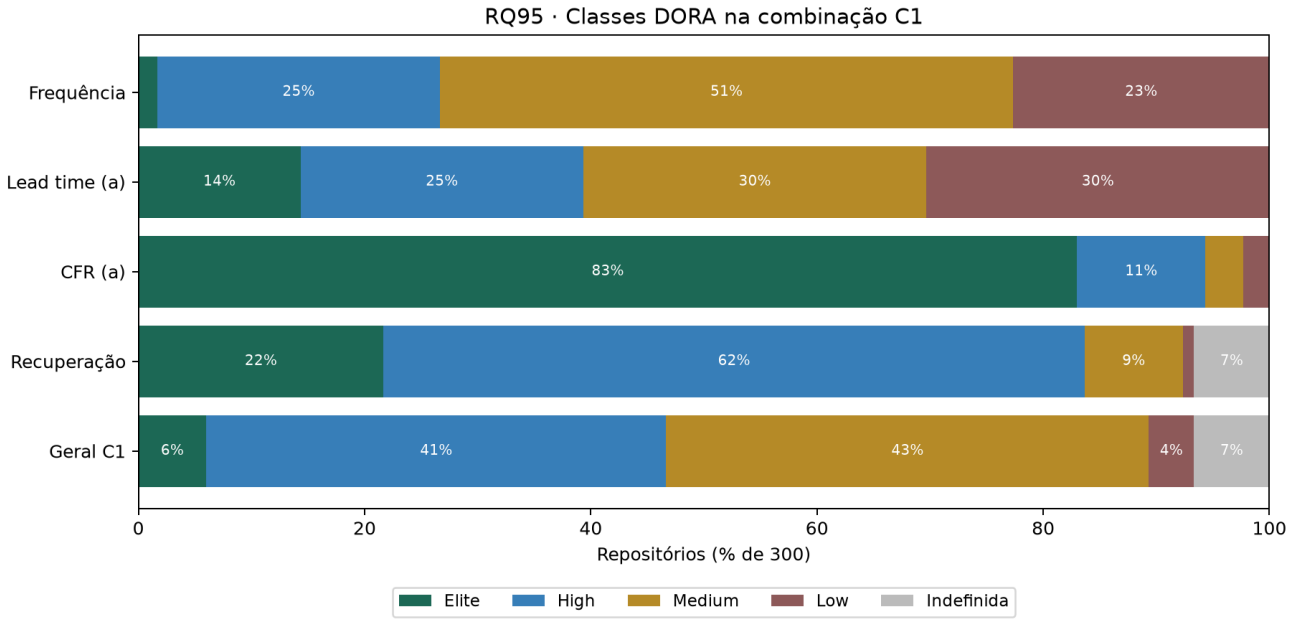


Figura 9 — Classes por métrica e classificação geral na combinação C1 (fonte: RQ95).

4.3 Discussão: hipóteses, interpretação e limites

Hipótese	Resultado da Sprint 3	Síntese
H1	Mediana 0,479 < limite previsto de 0,5; Medium/High predominam.	Parcial
H2	Lead time (b) não sistematicamente menor; p=0,115.	Não confirmada
H3	CFR de entrega (18,75%) > CFR de CI (4,57%); baixa correlação.	Parcial
H4	Recuperação mediana 2,72 h; parte dos episódios censurada.	Compatível
H5	ρ positivo nos dois proxies; efeito mecânico no CFR (b).	Não confirmada em termos simples
H6	4/16 fatores×métrica significativos; tipo do	Parcial / pendente

Hipótese	Resultado da Sprint 3	Síntese
	projeto sem consenso.	
H7	41,6% variam em alguma alternativa; efeito depende da troca.	Parcial

A discrepância entre medidas de CI e de entrega (RQ03) e as diferenças entre classificações (RQ07) mostram que o resultado pode refletir mais a definição operacional do que o comportamento real da equipe. A amostra é observacional e não probabilística, concentrada em projetos populares. A classificação não deve ser usada como ranking de produtividade entre pessoas ou organizações.

Ameaças à validade: (construto) release ≠ deploy e CI failure ≠ incidentes em produção; (interna) tamanho, idade e automação do projeto confundem relações; (externa) seleção por popularidade e critérios mínimos; (conclusão) assimetria, múltiplos testes e dependência de heurística sem padrão-ouro validado. A janela configurada é provisória. Os relatórios locais RQ91–RQ98 estão preenchidos, mas o artigo resultados.tex ainda mantém marcadores antigos e deve ser sincronizado antes da entrega científica definitiva.

5. Conclusão

A Sprint 3 cumpriu a produção técnica das análises RQ01–RQ07 sobre 300 repositórios, com figuras e métricas auditáveis no repositório. O resultado central é que velocidade e estabilidade aparentes variam bastante entre projetos e, sobretudo, entre definições: a frequência mediana foi 0,48 release/semana, o CFR de CI mediano 4,57% e o CFR de entrega por heurística 18,75%; 41,6% dos projetos com classe nas sete combinações mudam de classificação em alguma delas.

Foram identificadas contribuições complementares em robustez, censura, cadência temporal, comparação de heurísticas e controle de oportunidade de patch. Antes da submissão final do Lab03, recomenda-se confirmar a janela com o professor, concluir a rotulação humana independente e o consenso, calcular Fleiss κ e F1 real da heurística, conferir Assignees/WIP com print do GitHub Projects e sincronizar o artigo SBC, que contém trechos desatualizados. Essas pendências não anulam os cálculos existentes, mas limitam sua validade externa e a conclusão sobre o CFR (b).

6. Referências e fontes de reprodutibilidade

- FORSGREN, N.; HUMBLE, J.; KIM, G. Accelerate: The Science of Lean Software and DevOps. IT Revolution, 2018.
- DORA. Software delivery performance metrics. https://dora.dev/guides/dora-metrics-four-keys/ (acesso em 22/10/2026).
- GitHub. REST API documentation — Releases, Actions workflow runs, commits e rate limits. https://docs.github.com/en/rest.
- Enunciado Lab03 — Mineração de métricas DORA, disciplina Laboratório de Experimentação de Software, PUC Minas, fornecido no contexto do estudo.
- Repositório: https://github.com/BernardoApl/metrica-software; GitHub Project: https://github.com/users/BernardoApl/projects/2/views/1.
- Fontes versionadas: dados/lab03_final/{resumo_execucao.json, metricas_repositorios.csv, releases.csv, workflow_runs.csv.gz}; entregas/laboratorio-03/sprint-03/RQ91–RQ98/{resumo.json, RELATORIO.md, *.csv, *.png}; artigo/{introducao.tex, resultados.tex, discussao.tex}.
- Material complementar de análise e visualização de dados fornecido: “Análise de Dados Aplicada à Experimentação em Engenharia de Software”, junho/2026. Vídeo de referência solicitado no template: https://www.youtube.com/shorts/YwnaeO95AN8.